



Đồ án Chuyên Ngành Phishing Website Detector Machine Learning Chính Thức

Công nghệ Thông tin (Trường Đại Học Công Nghệ Tp.Hcm)



Scan to open on Studeersnel

BÁO CÁO ĐỒ ÁN CHUYÊN NGÀNH**CONTENT-BASED PHISHING DETECTION VIA MACHINE
LEARNING MODELS**Ngành: **CÔNG NGHỆ THÔNG TIN**Chuyên ngành: **AN NINH MẠNG**Giảng viên hướng dẫn: **Đinh Huỳnh Tuệ Tuệ**

Sinh viên thực hiện:

- | | | |
|---------------------|------------------|--------------|
| 1. Lê Ngọc Nhật Lâm | MSSV: 2180600751 | Lớp: 21DTHA5 |
| 2. Lê Hoài Khang | MSSV: 2180600601 | Lớp: 21DTHA5 |

TP. Hồ Chí Minh, 2024

BÁO CÁO ĐỒ ÁN CHUYÊN NGÀNH

PHISHING WEBSITE DETECTOR MACHINE LEARNING

Ngành: **CÔNG NGHỆ THÔNG TIN**

Chuyên ngành: **AN NINH MẠNG**

Giảng viên hướng dẫn: **Đinh Huỳnh Tuệ Tuệ**

Sinh viên thực hiện:

- | | | |
|---------------------|------------------|--------------|
| 1. Lê Ngọc Nhật Lâm | MSSV: 2180600751 | Lớp: 21DTHA5 |
| 2. Lê Hoài Khang | MSSV: 2180600601 | Lớp: 21DTHA5 |

TP. Hồ Chí Minh, 2024

LỜI MỞ ĐẦU

Trong thời đại cách mạng công nghiệp 4.0, thương mại điện tử đã trở nên phổ biến và các tiện ích số hóa ngày càng phát triển, mang lại nhiều lợi ích to lớn trong cuộc sống. Tuy nhiên, đi kèm với đó là những nguy cơ tiềm ẩn, đặc biệt là các mối đe dọa liên quan đến bảo mật thông tin như phishing.

Vì vậy, nhóm em thực hiện đề án “Phishing Website Detector Using Machine Learning” nhằm xây dựng giải pháp phát hiện và ngăn chặn các trang web lừa đảo. Nhóm xin gửi lời cảm ơn sâu sắc đến GVHD Cô Đinh Huỳnh Tuệ Tuệ đã tận tình hướng dẫn. Do còn nhiều hạn chế, nhóm rất mong nhận được ý kiến đóng góp từ thầy cô và các bạn để hoàn thiện chương trình hơn nữa.

LỜI CẢM ƠN

Lời đầu tiên, chúng em xin chân thành cảm ơn cô Đinh Huỳnh Tuệ Tuệ hướng dẫn đồ án chuyên ngành cho chúng em.

Sau thời gian học tập và tìm hiểu dưới sự hướng dẫn của cô, chúng em đã rút ra được rất nhiều kinh nghiệm về cách thức phân tích và thiết kế cũng như kỹ năng làm việc mà không chỉ đơn giản là đọc trong sách vở có thể có được và một lần nữa, chúng em xin gửi lời cảm ơn sâu sắc nhất đến cô vì đã dạy bảo và hướng dẫn những kiến thức chuyên môn cần có để chúng em áp dụng tốt nhất những gì đã được học suốt những thời gian qua.

Trong quá trình thực hiện và làm báo cáo, do còn thiếu nhiều kinh nghiệm thực tế nên không tránh khỏi những sai sót. Chúng em rất mong nhận được những ý kiến đóng góp của cô để giúp chúng em trong lĩnh vực này được hoàn thiện hơn. Đó là hành trang quý giá giúp chúng em hoàn thiện kiến thức của mình sau này.

Chúng em xin chân thành cảm ơn và trân trọng kính chào!

MỤC LỤC

LỜI MỞ ĐẦU.....	1
LỜI CẢM ƠN.....	2
MỤC LỤC.....	3
DANH MỤC HÌNH ẢNH.....	iv
DANH MỤC BẢNG.....	v
1 CHƯƠNG 1: TỔNG QUAN.....	1
1.1 Tổng quan đề tài.....	1
1.2 Nhiệm vụ đồ án.....	1
1.3 Cấu trúc đồ án.....	2
1.1.1 Giới thiệu.....	2
1.1.2 Tổng quan lý thuyết.....	3
1.1.3 Phương pháp nghiên cứu.....	3
1.1.4 Kết quả và thảo luận.....	4
1.1.5 Kết luận.....	4
1.1.6 Tài liệu tham khảo.....	4
2 CHƯƠNG 2: CƠ SỞ LÝ THUYẾT.....	5
2.1 Khái niệm về Phishing.....	5
2.2 Hiện trạng Phishing hiện nay.....	5
2.3 Khái niệm về Machine Learning (ML).....	5
2.4 Classification Algorithms (Thuật toán phân loại).....	7
2.5 Các phương pháp ML :	7
2.5.1 Decision Tree.....	7
2.5.2 Random Forest.....	8
2.5.3 AdaBoost.....	9
2.6 Dataset.....	13
2.6.1 PhishTank.....	14
2.6.2 Alexa Top Sites.....	16
2.7 Feature Extraction (Trích xuất đặc trưng).....	18
2.8 Training and Testing (Đào tạo và kiểm tra).....	19
2.8.1 Quá trình Đào Tạo (Training).....	19
2.8.2 Quá trình Kiểm Tra (Testing).....	20

2.9 Evaluation Metrics (Chỉ số đánh giá).....	21
2.10 Data Collector.....	25
2.12 Phương pháp (Methodology).....	34
3 CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM.....	35
3.1 Quá trình tạo file CSV.....	35
3.2 Quá trình train dữ liệu.....	37
4 CHƯƠNG 4: KẾT LUẬN VÀ KIẾN NGHỊ.....	41
4.1 Kết luận.....	41
4.2 Kiến nghị.....	41
TÀI LIỆU THAM KHẢO.....	45

DANH MỤC HÌNH ẢNH

Hình 2.1 Thống kê % Website Phishing & Hợp pháp.....	14
Hình 2.2 Sơ đồ mô phỏng quá trình.....	21
Hình 3.1 Đọc dữ liệu từ PhishTank.....	35
Hình 3.2 Đọc dữ liệu từ Alexa Top Sites.....	35
Hình 3.3 Lấy cột URL và chuyển thành danh sách.....	35
Hình 3.4 Lưu DataFrame Unsafe vào file.....	36
Hình 3.5 Lưu DataFrame Safe vào file.....	36
Hình 3.6 Biểu đồ cột so sánh của 3 mô hình.....	38
Hình 3.7 Giao diện Website.....	39
Hình 3.8 Chọn Model cho Machine Learning.....	39
Hình 3.9 Giao diện nhập 1 url bất kì kết quả trả về : An toàn.....	40
Hình 3.10 Giao diện nhập 1 url bất kì kết quả trả về : Không an toàn.....	40
Hình 3.11 Train thuật toán và kết quả đạt được.....	40

DANH MỤC BẢNG

Bảng 2.1 Vai trò – ưu – nhược điểm của 3 mô hình.....	11
Bảng 3.1 So sánh và nhận xét tổng quan 3 mô hình.....	38

CHƯƠNG 1: TỔNG QUAN

1.1 Tổng quan đề tài

Trước sự tiến bộ vượt bậc của công nghệ thông tin, máy tính ngày nay đã trở thành một phần không thể thiếu và trải rộng trong cuộc sống hàng ngày. Tuy nhiên, điều này cũng mở ra cánh cửa cho các cuộc tấn công mạng đầy nguy hiểm, từ việc phá hoại máy tính đến mục đích lợi ích kinh tế, đe dọa đến sự an toàn của chúng ta ngày càng nghiêm trọng và phức tạp hơn. Trong số đó, Phishing website là một trong những mối đe dọa nghiêm trọng nhất, bởi chúng lợi dụng lòng tin của người dùng để đánh cắp thông tin cá nhân và tài chính. Học máy, với khả năng tự học và thích ứng từ dữ liệu, đã mở ra một hướng đi mới trong việc phát hiện Phishing website. Bằng cách huấn luyện các thuật toán trên một lượng lớn dữ liệu về Phishing website và website an toàn, chúng ta có thể xây dựng các mô hình có khả năng phân loại chính xác các website mới.

Từ đó, em hy vọng sẽ đóng góp một phần quan trọng vào lĩnh vực này và cung cấp các phương pháp hiệu quả để bảo vệ người dùng khỏi các lừa đảo mạng. Trong báo cáo này, chúng em sẽ trình bày về quá trình triển khai các phát hiện các website lừa đảo bằng học máy.

1.2 Nhiệm vụ đồ án

Một trang web lừa đảo là một trong những hình thức tấn công thuộc Social Engineering phổ biến hiện nay, giả mạo các URL và trang web đáng tin cậy nhằm chiếm đoạt thông tin người dùng.

Mục tiêu của dự án này là nghiên cứu và thử nghiệm, so sánh các mô hình máy học và mạng nơ-ron sâu trên tập dữ liệu được tạo ra, nhằm chọn lọc phương pháp tối ưu nhất để xây dựng một ứng dụng kiểm tra URL của các website. Tập dữ liệu bao gồm cả URL của các trang web lừa đảo và hợp pháp, từ đó các đặc trưng dựa trên URL và nội dung trang web được trích xuất. Hiệu suất của từng mô hình sẽ được đánh giá và so sánh để xác định giải pháp tốt nhất.

Ý nghĩa khoa học và thực tiễn :

- **Ý nghĩa Khoa học :**

- + **Đóng góp vào lĩnh vực bảo mật thông tin:** Nghiên cứu này góp phần làm phong phú kho tàng kiến thức về các phương pháp phát hiện tấn công mạng, đặc biệt là loại hình tấn công phổ biến dễ tiếp cận người sử dụng Social engineering.
- + **Ứng dụng các kỹ thuật học máy tiên tiến:** Nghiên cứu sẽ khai thác các thuật toán học máy hiện đại để giải quyết một vấn đề thực tế, qua đó đánh giá hiệu quả và khả năng ứng dụng của các thuật toán này.
- + **Mở rộng hiểu biết về các đặc trưng của website phishing:** Qua quá trình xây dựng mô hình, các nhà nghiên cứu có thể khám phá ra những đặc trưng mới, phức tạp hơn của các website phishing, từ đó đưa ra các biện pháp phòng ngừa hiệu quả hơn.
- + **Đối tượng , phạm vi và giới hạn nghiên cứu:**
 - Đối tượng nghiên cứu: Các thuật toán học máy được sử dụng để phân loại website, bao gồm các thuật toán truyền thống như Random Forest, SVM và các thuật toán học sâu như mạng neural.
 - Phạm vi nghiên cứu: Nghiên cứu sẽ tập trung vào việc thiết kế, xây dựng và đánh giá các mô hình học máy để phân loại website phishing.
 - Giới hạn nghiên cứu: Do thời gian và nguồn lực có hạn, nghiên cứu chủ yếu tập trung vào các cuộc tấn công phishing thông qua website, có thể không bao gồm các hình thức tấn công khác như phishing qua email hoặc điện thoại.

1.3 Cấu trúc đề án

1.1.1 Giới thiệu

- **Tình hình chung về vấn đề:**
 - + Định nghĩa phishing, tác hại của tấn công phishing.
 - + Thống kê về các vụ tấn công phishing trên thế giới và Việt Nam.
- **Mục tiêu nghiên cứu:**
 - + Mục tiêu tổng quát và các mục tiêu cụ thể của nghiên cứu.
 - + Đóng góp của nghiên cứu vào lĩnh vực bảo mật thông tin.
- **Câu hỏi nghiên cứu:**

- + Các câu hỏi nghiên cứu chính mà đồ án sẽ trả lời.
- **Phạm vi nghiên cứu:**
 - + Đối tượng nghiên cứu (website, dữ liệu website).
 - + Các loại tấn công phishing được xem xét.
 - + Các thuật toán học máy được sử dụng.

1.1.2 Tổng quan lý thuyết

- **Học máy:**
 - + Khái niệm cơ bản về học máy.
 - + Các thuật toán học máy phổ biến (Decision Tree, Random Forest, AdaBoost).
 - + Ưu nhược điểm của từng thuật toán.
- **Phát hiện xâm nhập:**
 - + Các phương pháp phát hiện xâm nhập truyền thống và hiện đại.
 - + Các đặc trưng thường được sử dụng để phát hiện tấn công phishing.
- **Phishing:**
 - + Các kỹ thuật tấn công phishing phổ biến.
 - + Các đặc trưng của website phishing.

1.1.3 Phương pháp nghiên cứu

- **Thu thập dữ liệu:**
 - + Nguồn dữ liệu (dataset công khai, thu thập dữ liệu tự động) từ nguồn PhishTank và Alexa Top Sites
 - + Tiền xử lý dữ liệu (làm sạch, chuẩn hóa).
- **Trích xuất đặc trưng:**
 - + Các đặc trưng tĩnh (URL, HTML, WHOIS).
 - + Các đặc trưng động (JavaScript, nội dung trang).
 - + Phương pháp trích xuất đặc trưng.
- **Xây dựng mô hình:**
 - + Mô tả chi tiết các mô hình được xây dựng.
 - + Các tham số của mô hình.
 - + Quy trình huấn luyện mô hình.

- **Đánh giá mô hình:**
 - + Các chỉ số đánh giá (accuracy, precision, recall).
 - + So sánh hiệu quả của các mô hình.

1.1.4 Kết quả và thảo luận

- **Kết quả thực nghiệm:**
 - + Trình bày kết quả đánh giá các mô hình.
 - + Phân tích các kết quả.
- **Thảo luận:**
 - + So sánh kết quả với các nghiên cứu trước đó.
 - + Nhận xét về hiệu quả của các phương pháp.
 - + Phân tích nguyên nhân của các sai số.

1.1.5 Kết luận

- **Tóm tắt kết quả nghiên cứu:**
 - + Tổng kết những kết quả quan trọng đạt được.
- **Đóng góp của nghiên cứu:**
 - + Đánh giá đóng góp của nghiên cứu đối với lĩnh vực bảo mật thông tin.
- **Hướng phát triển trong tương lai:**
 - + Đề xuất các hướng nghiên cứu tiếp theo.

1.1.6 Tài liệu tham khảo

- **Danh sách các tài liệu tham khảo:**
 - + Sách, bài báo, website.

CHƯƠNG 2: CƠ SỞ LÝ THUYẾT

2.1 Khái niệm về Phishing

Phishing, hay còn gọi là tấn công lừa đảo, là một loại tấn công mạng trong đó kẻ xấu mạo danh các tổ chức hoặc cá nhân uy tín nhằm lừa người dùng cung cấp thông tin nhạy cảm như mật khẩu, số thẻ ngân hàng, hoặc thông tin tài chính khác.

2.2 Hiện trạng Phishing hiện nay

Hiện nay, phishing đang trở nên phổ biến với các phương thức tấn công ngày càng tinh vi, bao gồm việc sử dụng email, mạng xã hội và các trang web giả mạo. Báo cáo gần đây cho thấy số lượng vụ tấn công phishing toàn cầu không ngừng gia tăng, đặc biệt nhắm đến các lĩnh vực như tài chính, thương mại điện tử và giáo dục.

Để phòng chống phishing, việc nâng cao nhận thức của người dùng đóng vai trò quan trọng. Người dùng cần được đào tạo để nhận biết các dấu hiệu của email hoặc trang web giả mạo, kiểm tra kỹ URL và ưu tiên sử dụng các biện pháp xác thực đa yếu tố (MFA). Bên cạnh đó, công nghệ phát hiện cũng là một yếu tố then chốt, như việc cài đặt các công cụ chống phishing trên trình duyệt và hệ thống mạng, sử dụng phần mềm bảo mật email, và duy trì cơ sở dữ liệu về các URL độc hại như PhishTank.

Các tổ chức cần quản lý và bảo vệ dữ liệu hiệu quả thông qua việc cập nhật thường xuyên phần mềm và hệ thống bảo mật. Đặc biệt, ứng dụng công nghệ Machine Learning (ML) đã chứng minh hiệu quả trong việc phát hiện phishing. Các thuật toán ML có thể phân tích đặc trưng của URL, nội dung HTML hoặc hành vi người dùng để nhận diện các mối đe dọa một cách nhanh chóng và chính xác hơn.

2.3 Khái niệm về Machine Learning (ML)

Machine Learning (Học máy) là một nhánh của trí tuệ nhân tạo, nơi máy tính được lập trình để học từ dữ liệu và tự cải thiện hiệu suất mà không cần lập trình trực tiếp. Trong lĩnh vực phát hiện phishing, ML có thể tự động nhận diện các mẫu (patterns) đặc trưng để phân biệt giữa các website lừa đảo và hợp pháp.

Các phương pháp ML cho phishing:

- Decision Tree
- Random Forest
- AdaBoost

Phương pháp đề xuất trong đồ án:

Ba phương pháp được chọn:

- **Random Forest** được lựa chọn nhờ khả năng đạt độ chính xác cao và khả năng giảm thiểu hiện tượng overfitting. Đây là một mô hình ensemble dựa trên việc xây dựng nhiều cây quyết định (decision trees) và tổng hợp kết quả của chúng để đưa ra dự đoán cuối cùng. Việc sử dụng nhiều cây giúp mô hình giảm thiểu sai số do biến động dữ liệu (variance) và sai số do độ chệch (bias), mang lại hiệu suất tốt trên các tập dữ liệu phức tạp. Ngoài ra, Random Forest còn có khả năng tự động xử lý dữ liệu thiếu và ước tính mức độ quan trọng của các đặc trưng, giúp ích cho việc phân tích dữ liệu và giải thích mô hình.
- **AdaBoost** (Adaptive Boosting) được chọn vì khả năng tăng cường hiệu quả của các mô hình yếu (weak learners) như Decision Trees, đồng thời xử lý tốt dữ liệu không cân bằng. Thuật toán này hoạt động dựa trên nguyên tắc kết hợp các mô hình yếu để tạo thành một mô hình mạnh bằng cách ưu tiên học từ các lỗi trong các lần lặp trước. AdaBoost đặc biệt hiệu quả khi dữ liệu chứa các mẫu khó phân loại, nhờ khả năng điều chỉnh trọng số của các mẫu này để cải thiện độ chính xác. Điều này làm cho AdaBoost trở thành một sự lựa chọn phù hợp trong các bài toán phức tạp như phát hiện phishing.
- **Decision Tree** được lựa chọn vì tính đơn giản, dễ hiểu và dễ triển khai. Đây là một thuật toán dựa trên việc phân tách dữ liệu theo các đặc trưng để tạo ra một cấu trúc dạng cây, trong đó các nút đại diện cho điều kiện phân tách và các nhánh đại diện cho các kết quả có thể xảy ra. Decision Tree không yêu cầu xử lý đặc biệt đối với dữ liệu thiếu hoặc không tuyến tính, và có thể tạo ra các mô hình dễ dàng giải thích, giúp hiểu rõ quy trình dự đoán. Mặc dù dễ gặp hiện tượng overfitting khi dữ liệu lớn và phức tạp, Decision Tree vẫn là lựa chọn phù hợp trong giai đoạn triển khai ban đầu để kiểm tra và hiểu các đặc trưng của dữ liệu.

- Việc kết hợp sử dụng các thuật toán này không chỉ mang lại sự đa dạng trong cách tiếp cận vấn đề mà còn cho phép so sánh và lựa chọn phương pháp tối ưu nhất dựa trên hiệu suất thực tế trên tập dữ liệu.

2.4 Classification Algorithms (Thuật toán phân loại)

- **Thuật toán phân loại** là một trong những công cụ quan trọng trong học máy, được sử dụng để dự đoán nhãn lớp (class label) cho một đối tượng dựa trên các đặc trưng của nó. Ví dụ, trong email, chúng ta có thể sử dụng thuật toán phân loại để phân loại email thành thư rác hoặc không phải thư rác.
- **Tại sao cần phân loại?**
- + **Tự động hóa quy trình:** Giảm thiểu sự can thiệp của con người trong các tác vụ lặp đi lặp lại.
- + **Tìm kiếm thông tin hiệu quả:** Tìm kiếm thông tin liên quan nhanh chóng và chính xác hơn.
- + **Đưa ra quyết định:** Hỗ trợ trong việc đưa ra các quyết định kinh doanh quan trọng dựa trên dữ liệu.
- + **Phát hiện bất thường:** Phát hiện các hoạt động bất thường hoặc các mẫu dữ liệu không phù hợp.

2.5 Các phương pháp ML :

2.5.1 *Decision Tree*

2.5.1.1 *Khái niệm*

- **Decision Tree** là một thuật toán học máy dựa trên cấu trúc dạng cây. Mỗi nút (node) trong cây đại diện cho một đặc điểm hoặc thuộc tính (feature), và các nhánh (branch) là các điều kiện kiểm tra trên các thuộc tính đó, dẫn đến các nút con. Cuối cùng, các lá (leaf) đại diện cho nhãn đầu ra (phân loại là lừa đảo hoặc không lừa đảo).
- Thuật toán Decision Tree phân chia dữ liệu thành các nhóm nhỏ hơn dựa trên giá trị của các thuộc tính để tìm ra nhánh phân loại chính xác nhất.

2.5.1.2 Chức năng

- + Phân loại các trang web là lừa đảo hoặc không lừa đảo dựa trên các đặc điểm của chúng.
- + Dễ hiểu và giải thích, giúp người dùng dễ dàng hiểu lý do mô hình đánh giá một trang web là lừa đảo.

2.5.1.3 Vai trò

- + **Decision Tree** có vai trò là một mô hình cơ bản và dễ triển khai cho phát hiện lừa đảo. Nó phù hợp khi hệ thống yêu cầu mô hình đơn giản và dễ giải thích.
- + Thường được dùng làm nền tảng cho các mô hình phức tạp hơn như **Random Forest** và **AdaBoost**.

2.5.1.4 Nhiệm vụ

- + Xác định các đặc điểm quan trọng của trang web (như độ dài URL, sử dụng HTTPS, liên kết bên ngoài).
- + Phân loại các trang dựa trên các đặc điểm này, giúp tạo ra một cây quyết định phân loại các trang có dấu hiệu lừa đảo.

2.5.2 Random Forest

2.5.1.5 Khái niệm

- **Random Forest** là một mô hình học máy kết hợp nhiều cây quyết định (Decision Trees) để tạo thành một "rừng cây" (forest). Các cây này hoạt động độc lập, sau đó hệ thống sẽ tổng hợp kết quả dự đoán từ tất cả các cây để đưa ra quyết định cuối cùng.
- Phương pháp này giúp giảm thiểu overfitting (quá khớp) và tăng cường độ chính xác.

2.5.1.6 Chức năng

- + Cung cấp dự đoán chính xác và ổn định hơn so với một cây quyết định duy nhất.
- + Thích ứng tốt với dữ liệu có nhiều đặc điểm và có khả năng tìm ra các mối quan hệ phức tạp trong dữ liệu.

2.5.1.7 Vai trò

- + **Random Forest** là một mô hình mạnh mẽ và hiệu quả trong việc phát hiện lừa đảo trên website nhờ khả năng kết hợp các cây quyết định và tổng hợp kết quả dự đoán.
- + Phù hợp khi cần mô hình có hiệu suất cao và ít bị ảnh hưởng bởi sự thay đổi nhỏ trong dữ liệu.

2.5.1.8 Nhiệm vụ

- + Huấn luyện trên các tập dữ liệu ngẫu nhiên để tạo thành nhiều cây quyết định, mỗi cây sẽ đưa ra dự đoán riêng.
- + Tổng hợp các dự đoán từ nhiều cây để đưa ra quyết định cuối cùng về việc một trang web có lừa đảo hay không.
- + Tăng cường độ chính xác và giảm thiểu rủi ro overfitting.

2.5.3 AdaBoost

2.5.1.9 Khái niệm

AdaBoost là một thuật toán dựa trên phương pháp Boosting, tương tự như XGBoost. Nó cũng sử dụng nhiều cây quyết định nhưng cách thức kết hợp và học hỏi từ các cây này có đôi chút khác biệt. Cụ thể, AdaBoost sẽ tập trung vào các mẫu dữ liệu mà các cây trước đó dự đoán sai, dần dần tăng trọng số của chúng để các cây tiếp theo chú ý hơn đến những mẫu này.

2.5.1.10 Chức năng

- + **Tăng cường độ chính xác:** AdaBoost giúp cải thiện đáng kể độ chính xác của mô hình bằng cách kết hợp nhiều cây quyết định yếu thành một cây quyết định mạnh.
- + **Xử lý dữ liệu không cân bằng:** AdaBoost đặc biệt hiệu quả trong việc xử lý các tập dữ liệu có sự phân bố không đồng đều giữa các lớp, nhờ cơ chế điều chỉnh trọng số cho các mẫu dữ liệu.

2.5.1.11 Vai trò

- + **Phân loại:** AdaBoost được sử dụng rộng rãi trong các bài toán phân loại, đặc biệt là khi dữ liệu có nhiều nhiễu hoặc các lớp không phân tách rõ ràng.

- + **Phát hiện ngoại lệ:** AdaBoost cũng có thể được áp dụng để phát hiện các mẫu dữ liệu bất thường hoặc ngoại lệ.

2.5.1.12 Nhiệm vụ

- + **Huấn luyện tuần tự:** AdaBoost huấn luyện các cây quyết định tuần tự, với mỗi cây được xây dựng dựa trên thông tin từ các cây trước đó.
- + **Điều chỉnh trọng số:** AdaBoost điều chỉnh trọng số của các mẫu dữ liệu sau mỗi lần lặp để tập trung vào các mẫu khó phân loại.
- + **Kết hợp các cây quyết định:** AdaBoost kết hợp đầu ra của các cây quyết định thành một dự đoán cuối cùng.

Bảng so sánh ví dụ của ba mô hình :

ML Model	Accuracy	Recall	Precision	Vai trò chính	Ưu điểm	Nhược điểm
AdaBoost	0.9775 (97.75%)	0,1648 (16.48%)	0.4866 (48.66)	Cải thiện hiệu suất của các mô hình máy học	Khả năng xử lý dữ liệu không cân bằng tốt. - Độ chính xác cao. - Ít bị overfitting.	Nhạy cảm với dữ liệu nhiễu. - Khó điều chỉnh hyperparameter.
Random Forest	0,9908 (99.08%)	0,6617 (66.17%)	0.6896 (68.96%)	Mô hình ổn định và cân bằng	Tăng độ chính xác nhờ kết hợp nhiều cây quyết định, ít overfitting hơn	Khó giải thích hơn Decision Tree
Decision Tree	0.9852 (98.52%)	0,6916 (69.16%)	0.6896 (68.96%)	Đơn giản, dễ hiểu	Dễ hiểu và dễ triển khai, phù hợp với các bài toán đơn giản	Dễ bị overfitting, độ chính xác thấp

Bảng 2.1 Vai trò – ưu – nhược điểm của 3 mô hình

1. Accuracy (Độ chính xác)

- Công dụng:

- + Accuracy đo lường tỷ lệ mẫu được dự đoán đúng (cả **Positive** và **Negative**) trên tổng số mẫu.
- + Nó phản ánh hiệu suất tổng thể của mô hình, đặc biệt hữu ích khi dữ liệu cân bằng (số lượng Positive và Negative gần tương đương).

- Công thức:

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN}$$

TP (True Positive): Dự đoán đúng lớp Positive.

TN (True Negative): Dự đoán đúng lớp Negative.

FP (False Positive): Dự đoán sai lớp Positive.

FN (False Negative): Dự đoán sai lớp Negative.

2. Precision (Độ chính xác của dự đoán Positive)

- Công dụng:

- + Precision đánh giá tính chính xác của các dự đoán thuộc lớp Positive. Nó đặc biệt hữu ích khi chi phí của các dự đoán sai Positive (FP) cao.
- + Ví dụ: Trong chẩn đoán bệnh, Precision cao giúp hạn chế việc báo động sai (False Alarms).

- Công thức:

$$Precision = \frac{TP}{TP + FP}$$

3. Recall (Độ nhạy, hay True Positive Rate)

- Công dụng:

- + Recall đo lường khả năng mô hình tìm ra các mẫu Positive thật sự. Nó quan trọng trong các bài toán mà việc bỏ sót Positive (FN) là không thể chấp nhận được.

+ Ví dụ: Trong y tế, bỏ sót một bệnh nhân mắc bệnh (FN) có thể dẫn đến hậu quả nghiêm trọng.

- **Công thức:**

$$Recall = \frac{TP}{TP + FN}$$

4. F1 Score (Trung bình điều hòa giữa Precision và Recall)

- **Công dụng:**

+ F1 Score là thước đo cân bằng giữa Precision và Recall, đặc biệt hữu ích khi dữ liệu không cân bằng.


+ Nó kết hợp cả hai yếu tố: khả năng dự đoán đúng (Precision) và khả năng tìm kiếm toàn diện (Recall).

- **Công thức:**

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

2.6 Dataset

- Dataset chính được sử dụng là từ **PhishTank** và **Alexa Top Sites**, kết hợp để đảm bảo tính đa dạng và độ tin cậy. Các đặc trưng được trích xuất bao gồm thông tin URL, đặc điểm về HTML, và hành vi của trang web.
- Tổng cộng có 26587 website trong đó
 - + 16062 Website hợp pháp
 - + 10525 Website Phishing



Hình 2.1 Thống kê % Website Phishing & Hợp pháp

2.6.1 PhishTank

2.6.1.1 . Nguồn Gốc Dataset

Dataset được thu thập từ PhishTank, là nền tảng cộng đồng cho phép người dùng gửi và xác minh các URL nghi ngờ là lừa đảo. PhishTank cung cấp một cơ sở dữ liệu mở (open-source) về các trang web lừa đảo, được cập nhật liên tục bởi cộng đồng người dùng. Dữ liệu từ PhishTank là một nguồn tài nguyên quý giá cho các nhà nghiên cứu và phát triển các giải pháp chống lừa đảo trực tuyến.

2.6.1.2 Lý Do Chọn Dataset

- **Độ Tin Cậy:** PhishTank & là một trong những nguồn dữ liệu đáng tin cậy nhất về phishing, với sự xác minh từ cộng đồng.
- **Cập Nhật Thường Xuyên:** Dataset được cập nhật theo giờ, đảm bảo rằng thông tin luôn mới và chính xác.
- **Định Dạng Dễ Dàng:** Dữ liệu có sẵn ở nhiều định dạng (CSV, JSON), thuận tiện cho việc xử lý và phân tích.
- **Đầy Đủ và Đa Dạng:** Dataset bao gồm cả URLs hợp pháp và URLs lừa đảo, giúp cho việc huấn luyện mô hình phát hiện phishing trở nên hiệu quả hơn.
- **Cơ sở dữ liệu khoa học:** Google Scholar, IEEE Xplore, ACM Digital Library
- **Tạp chí chuyên ngành:** Journal of Information Security, IEEE Transactions on Information Forensics and Security, Computers & Security
- **Hội nghị:** Usenix Security Symposium, NDSS Symposium, ACM CCS
- **Các tổ chức nghiên cứu:** SANS Institute, CERT Coordination Center, ENISA

2.6.1.3 Cấu Trúc Dataset

- **Số Lượng Dữ Liệu:** Dataset bao gồm 64208 URLs ngẫu nhiên.
- **Nhãn Dữ Liệu:** Mỗi URL được gán nhãn:
 - 1: Phishing (lừa đảo)
- **Số Cột:** Dataset có 18 cột đặc trưng được trích xuất từ mỗi URL, bao gồm:
- **Đặc trưng dựa trên địa chỉ (Address-based features)**

- Đặc trưng dựa trên tên miền (Domain-based features)
- Đặc trưng dựa trên HTML và JavaScript

2.6.1.4 Các Đặc Trưng Chính

Dưới đây là danh sách các đặc trưng chính được sử dụng trong dataset:

Cột	Mô tả	Dạng dữ liệu	Ý nghĩa
phish_id	ID duy nhất cho mỗi trang web phishing.	Số nguyên	Dùng để định danh mỗi bản ghi, tránh trùng lặp dữ liệu.
url	Địa chỉ URL bị đánh dấu là phishing.	Chuỗi ký tự	Địa chỉ thực tế của trang lừa đảo, cần kiểm tra.
phish_detail_url	Liên kết chi tiết về trang phishing trên PhishTank.	Chuỗi ký tự	Thông tin bổ sung từ PhishTank, giúp xác thực và xem các chi tiết điều tra.
submission_time	Thời gian URL được báo cáo trên PhishTank.	Chuỗi ký tự	Hữu ích để theo dõi xu hướng và thời điểm xuất hiện của các cuộc tấn công lừa đảo.
verified	Trạng thái xác minh của URL (yes/no).	Chuỗi ký tự	Đảm bảo rằng URL đã được xác thực là phishing.
verification_time	Thời điểm URL được xác minh là phishing.	Chuỗi ký tự	Dùng để kiểm tra độ trễ giữa báo cáo và xác minh, đánh giá hiệu quả phản hồi của hệ thống.
online	URL còn hoạt động vào thời điểm báo cáo hay không (yes/no).	Chuỗi ký tự	Xác định xem URL có còn mối đe dọa không.
target	Mục tiêu bị giả mạo (ví dụ: ngân hàng, dịch vụ email, mạng xã hội).	Chuỗi ký tự	Xác định mục tiêu tấn công, giúp tập trung bảo vệ các dịch vụ phổ biến.

2.6.1.5 Phân Bố Dữ Liệu

- Training Set: (10525 URLs) được sử dụng để huấn luyện mô hình.

- **Shuffle Dữ Liệu:** Dữ liệu được xáo trộn để đảm bảo tính ngẫu nhiên và không thiên lệch.

2.6.1.6 Tại Sao Cần Dataset Này

- **Mạng internet đầy rẫy nguy hiểm:** Có rất nhiều trang web giả mạo để lừa người dùng cung cấp thông tin cá nhân như mật khẩu, số thẻ ngân hàng,...
- **Cần công cụ để bảo vệ:** Bộ dữ liệu này sẽ giúp chúng ta xây dựng các phần mềm, ứng dụng có khả năng phát hiện và cảnh báo người dùng khi truy cập vào những trang web độc hại này.
- **Dữ liệu thực tế rất quan trọng:** Chúng ta cần có những ví dụ thực tế về các trang web lừa đảo để "dạy" cho máy tính cách phân biệt chúng với các trang web bình thường.
- **Cảnh báo sớm để phòng tránh:** Bộ dữ liệu này sẽ giúp chúng ta xây dựng một hệ thống cảnh báo sớm, giống như một "tấm khiên" bảo vệ người dùng khỏi những nguy hiểm trên mạng.
- **Bảo vệ bạn và mọi người:** Cuối cùng, mục tiêu của chúng ta là giúp mọi người sử dụng internet một cách an toàn và tự tin hơn.

2.6.1.7 Cập Nhật và Bảo Trì

- **Cập Nhật Thường Xuyên:** Dataset được cập nhật thường xuyên bởi PhishTank, đảm bảo rằng thông tin luôn mới và chính xác.
- **Tải Về Phiên Bản Mới:** Có thể tải về phiên bản mới nhất của dataset để cập nhật mô hình, giúp cải thiện khả năng phát hiện.
- **Cộng Đồng Góp Phần:** Cộng đồng người dùng đóng góp vào việc xác minh và làm sạch dữ liệu, giúp duy trì chất lượng của dataset.

2.6.1.8 Hạn Chế

- **False Positives/Negatives:** Có thể có một số trường hợp false positives (nhận diện sai trang web hợp pháp là lừa đảo) và false negatives (không nhận diện được trang web lừa đảo).
- **Thời Gian Xác Minh:** Cần thời gian để xác minh các URLs mới, điều này có thể ảnh hưởng đến tốc độ phát hiện.
- **Phụ Thuộc Vào Cộng Đồng:** Chất lượng của dataset phụ thuộc vào sự đóng góp và xác minh của cộng đồng, có thể dẫn đến sự không đồng nhất trong dữ liệu

2.6.2 Alexa Top Sites

Trong tài liệu, nhóm nghiên cứu đã sử dụng một tập dữ liệu kết hợp từ nhiều nguồn khác nhau để xây dựng mô hình máy học nhằm phát hiện các trang web lừa đảo. Dưới đây là mô tả chi tiết về tập dữ liệu, các đặc trưng, nguồn gốc, lý do sử dụng, cũng như ưu nhược điểm của việc kết hợp với PhishTank.

2.6.1.9 Mô tả Tập Dữ Liệu

- **Kích thước Tập Dữ Liệu:** Tập dữ liệu ban đầu có 1.000.000 trang web.
- **Dữ Liệu Để Dự Đoán:** Sau khi xử lý, nhóm nghiên cứu đã thu được 16.062 trang web để dự đoán.

- **Tỷ Lệ Dữ Liệu Để Huấn Luyện:** Từ 1.000.000 trang web, tỷ lệ dữ liệu được sử dụng để huấn luyện có thể được tính toán dựa trên số lượng trang web còn lại sau khi loại bỏ các trang không hợp lệ hoặc không cần thiết.

2.6.1.10 Nguồn Gốc Tập Dữ Liệu

- **Alexa:** Tập dữ liệu chủ yếu được lấy từ danh sách Alexa, một trong những danh sách phổ biến nhất về các trang web.
- **PhishTank:** Đây là một nguồn dữ liệu quan trọng khác, cung cấp thông tin về các trang web lừa đảo đã được xác minh.

2.6.1.11 Tại Sao Sử Dụng Tập Dữ Liệu Này

- **Đại Diện Thực Tế:** Tập dữ liệu từ Alexa cung cấp một cái nhìn tổng quát về các trang web phổ biến, trong khi PhishTank cung cấp thông tin về các trang web lừa đảo, giúp mô hình học máy có thể phân loại chính xác hơn.
- **Tính Đa Dạng:** Việc kết hợp hai nguồn dữ liệu này giúp tăng cường tính đa dạng và độ chính xác của mô hình, vì nó bao gồm cả các trang web hợp lệ và không hợp lệ.

2.6.1.12 Ưu Nhược Điểm

Ưu Điểm	Nhược Điểm
Cung cấp một tập dữ liệu phong phú và đa dạng từ nhiều nguồn khác nhau.	Có thể có sự thiên lệch trong dữ liệu nếu một nguồn nào đó chiếm ưu thế.
Tăng cường khả năng phát hiện các trang web lừa đảo nhờ vào thông tin từ PhishTank.	Tập dữ liệu có thể chứa các trang web không còn hoạt động, ảnh hưởng đến độ chính xác.
Giúp cải thiện độ chính xác của mô hình học máy thông qua việc sử dụng các đặc trưng phong phú.	Cần phải xử lý và làm sạch dữ liệu để đảm bảo tính chính xác, điều này có thể tốn thời gian.

2.6.1.13 Các Đặc Trưng Sử Dụng

Các đặc trưng có thể bao gồm:

- Tình trạng phản hồi của trang web (status code).
- Độ dài nội dung của trang.
- Các yếu tố liên quan đến tên miền (domain features).
- Thông tin từ PhishTank về các trang web lừa đảo.

Việc sử dụng các đặc trưng này giúp mô hình có thể phân loại các trang web một cách hiệu quả hơn, từ đó nâng cao khả năng phát hiện các trang web lừa đảo.

2.7 Feature Extraction (Trích xuất đặc trưng)

Trích xuất đặc trưng là một quá trình quan trọng trong học máy, đặc biệt trong xử lý tín hiệu, hình ảnh và văn bản. Mục tiêu của quá trình này là chuyển đổi dữ liệu thô, thường có kích thước lớn và phức tạp, thành một tập hợp các đặc trưng có ý nghĩa và mang tính đại diện hơn, nhằm phục vụ cho các thuật toán học máy.

- **Tại sao cần trích xuất đặc trưng?**
 - + **Giảm chiều dữ liệu:** Dữ liệu thô thường có rất nhiều chiều, gây khó khăn cho các thuật toán học máy. Trích xuất đặc trưng giúp giảm chiều dữ liệu, loại bỏ thông tin nhiễu và tăng tốc độ tính toán.
 - + **Tăng cường khả năng tổng quát hóa:** Bằng cách chọn các đặc trưng quan trọng nhất, mô hình học máy có thể tập trung vào các thông tin có ý nghĩa, giảm thiểu nguy cơ quá khớp (overfitting).
 - + **Cải thiện hiệu suất:** Các đặc trưng được trích xuất tốt có thể giúp tăng độ chính xác và hiệu quả của các thuật toán học máy.
- **Các phương pháp trích xuất đặc trưng phổ biến**
- **Trích xuất đặc trưng thủ công:**
 - + **Lựa chọn đặc trưng:** Chọn các đặc trưng dựa trên kiến thức chuyên môn về lĩnh vực. Ví dụ: trong xử lý ảnh, ta có thể chọn các đặc trưng như màu sắc, hình dạng, kết cấu.
 - + **Phương pháp thống kê:** Sử dụng các thống kê như trung bình, phương sai, độ lệch chuẩn để trích xuất đặc trưng.
 - + **Biến đổi Fourier:** Chuyển đổi dữ liệu từ miền thời gian sang miền tần số để tìm các thành phần tần số quan trọng.
- **Trích xuất đặc trưng tự động:**
 - + **Phân tích thành phần chính (PCA):** Tìm các phương hướng biến thiên lớn nhất trong dữ liệu để giảm chiều.
 - + **Phân tích nhân tử độc lập (ICA):** Tìm các thành phần độc lập tuyến tính ẩn trong dữ liệu.

- + **T-SNE:** Một thuật toán giảm chiều không tuyến tính, giúp trực quan hóa dữ liệu đa chiều.
- + **Autoencoder:** Một loại mạng neural nhân tạo có khả năng học các đặc trưng ẩn trong dữ liệu.
- **Domain-Based Features:** Thông tin về tên miền như tuổi thọ, lưu lượng truy cập, và bản ghi DNS.
- **HTML/JS-Based Features:** Các yếu tố trong mã HTML hoặc JavaScript như việc sử dụng iframe, tùy chỉnh thanh trạng thái, và các phương thức chuyển hướng.
- **Address Bar Features:** Các đặc trưng liên quan đến thanh địa chỉ như độ dài URL, sự hiện diện của ký tự đặc biệt, và việc sử dụng dịch vụ rút gọn URL.

2.8 Training and Testing (Đào tạo và kiểm tra)


2.8.1 Quá trình Đào Tạo (Training)

- **Tập dữ liệu huấn luyện:** Đây là tập hợp lớn các URL đã được gán nhãn rõ ràng là phishing hoặc hợp lệ. Mỗi URL sẽ đi kèm với một loạt các đặc trưng, như độ dài URL, từ khóa, tên miền, v.v.
- **Thuật toán học máy:** Một thuật toán học máy phù hợp (ví dụ: Random Forest, SVM, Neural Network) sẽ được chọn để xây dựng mô hình.
- **Huấn luyện mô hình:**
 - + **Trích xuất đặc trưng:** Từ tập dữ liệu huấn luyện, các đặc trưng sẽ được trích xuất và chuyển thành dạng số để máy tính có thể xử lý.
 - + **Xây dựng mô hình:** Thuật toán học máy sẽ sử dụng các đặc trưng này để xây dựng một mô hình toán học. Mô hình này sẽ học cách phân biệt giữa các URL phishing và URL hợp lệ dựa trên các mẫu trong dữ liệu huấn luyện.
 - + **Cân chỉnh siêu tham số:** Các siêu tham số của mô hình (ví dụ: số lượng cây trong Random Forest, độ phức tạp của mạng neural) sẽ được điều chỉnh để đạt được hiệu suất tốt nhất.

2.8.2 *Quá trình Kiểm Tra (Testing)*

- **Tập dữ liệu kiểm tra:** Đây là một tập dữ liệu riêng biệt, không được sử dụng trong quá trình huấn luyện. Tập dữ liệu này cũng chứa các URL đã được gán nhãn.
- **Đánh giá mô hình:**
 - + **Dự đoán:** Mô hình được huấn luyện sẽ được sử dụng để dự đoán nhãn (phishing hoặc hợp lệ) cho các URL trong tập dữ liệu kiểm tra.
 - + **So sánh:** Kết quả dự đoán của mô hình sẽ được so sánh với nhãn thực tế của các URL trong tập dữ liệu kiểm tra.
 - + **Đánh giá hiệu suất:** Các chỉ số đánh giá như độ chính xác (accuracy), độ nhạy (recall), độ đặc hiệu (precision), F1-score sẽ được sử dụng để đánh giá hiệu suất của mô hình.
- **Các Chỉ Số Đánh Giá Hiệu Năng**
 - + **Độ chính xác (Accuracy):** Tỷ lệ các dự đoán đúng trên tổng số dự đoán.
 - + **Độ nhạy (Recall):** Tỷ lệ các URL phishing được mô hình phát hiện đúng.
 - + **Độ đặc hiệu (Precision):** Tỷ lệ các URL được mô hình đánh dấu là phishing thực sự là phishing.
- **Tại Sao Cần Phân Chia Dữ Liệu?**
 - + **Ngăn ngừa quá khớp (overfitting):** Nếu chỉ sử dụng một tập dữ liệu để cả huấn luyện và kiểm tra, mô hình có thể học thuộc lòng dữ liệu huấn luyện mà không có khả năng tổng quát hóa cho dữ liệu mới.
 - + **Đánh giá khách quan:** Việc sử dụng một tập dữ liệu kiểm tra độc lập giúp đánh giá một cách khách quan về khả năng của mô hình khi áp dụng vào dữ liệu thực tế.
- **Các Kỹ Thuật Nâng Cao :**
 - + **K-fold cross-validation:** Chia tập dữ liệu thành k phần bằng nhau. Lần lượt sử dụng k-1 phần để huấn luyện và 1 phần còn lại để kiểm tra. Lặp lại quá trình này k lần và tính trung bình các kết quả.

- + **Hyperparameter tuning:** Tìm kiếm các giá trị tối ưu cho các siêu tham số của mô hình bằng các kỹ thuật như grid search, random search hoặc Bayesian optimization.
- + **Ensemble methods:** Kết hợp nhiều mô hình đơn giản để tạo thành một mô hình mạnh hơn, ví dụ như Random Forest, Gradient Boosting.



Hình 2.2 Sơ đồ mô phỏng quá trình

2.9 Evaluation Metrics (Chỉ số đánh giá)

Khi xây dựng một mô hình học máy để phát hiện các trang web phishing, việc đánh giá hiệu quả của mô hình là vô cùng quan trọng. Để làm được điều này, chúng ta cần sử dụng các chỉ số đánh giá phù hợp.

- **Tại sao cần các chỉ số đánh giá?**
- + **So sánh các mô hình:** Giúp ta so sánh hiệu quả giữa các mô hình khác nhau để chọn ra mô hình tốt nhất.
- + **Đánh giá mức độ tin cậy:** Cho biết mức độ tin cậy của mô hình trong việc đưa ra dự đoán.

- + **Điều chỉnh mô hình:** Giúp ta điều chỉnh các hyperparameter của mô hình để cải thiện hiệu suất.
- **Các chỉ số đánh giá phổ biến**
- + **Độ chính xác (Accuracy):** Tỷ lệ các dự đoán đúng trên tổng số dự đoán. Đây là một chỉ số chung, tuy nhiên nó không phù hợp với các trường hợp dữ liệu không cân bằng (ví dụ, số lượng URL hợp lệ nhiều hơn số lượng URL phishing).
- + **Độ nhạy (Recall):** Tỷ lệ các URL phishing được mô hình phát hiện đúng. Chỉ số này quan trọng vì ta muốn phát hiện được tất cả các URL phishing để bảo vệ người dùng.
- + **Độ đặc hiệu (Precision):** Tỷ lệ các URL được mô hình đánh dấu là phishing thực sự là phishing. Chỉ số này quan trọng để tránh báo động giả.
- + **Ma trận nhầm lẫn (Confusion matrix):** Là một bảng thể hiện số lượng dự đoán đúng và sai của mô hình. Từ ma trận nhầm lẫn, ta có thể tính được các chỉ số đánh giá khác.
- + **Lựa chọn chỉ số đánh giá phù hợp:**
 - Việc lựa chọn chỉ số đánh giá phù hợp phụ thuộc vào mục tiêu của bài toán.
- + **Nếu mục tiêu chính là phát hiện tất cả các URL phishing:** Ta nên quan tâm đến độ nhạy.
- + **Nếu mục tiêu là giảm thiểu số lượng báo động giả:** Ta nên quan tâm đến độ đặc hiệu.
- + **Nếu muốn cân bằng giữa độ nhạy và độ đặc hiệu:** Ta nên sử dụng F1-score.

	Dự đoán là Phishing	Dự đoán là Hợp lệ
Thực tế là Phishing	TP (True Positive)	FN (False Negative)
Thực tế là Hợp lệ	FP (False Positive)	TN (True Negative)

THUẬT TOÁN	ƯU ĐIỂM	NHUỘC ĐIỂM	PHÙ HỢP VỚI
DECISION TREE	- Dễ hiểu, dễ giải thích - Tốc độ huấn luyện nhanh - Có thể xử lý cả dữ liệu số và danh mục	- Dễ bị overfitting, đặc biệt với dữ liệu ồn - Nhạy cảm với sự thay đổi nhỏ trong dữ liệu - Khó biểu diễn các mối quan hệ phức tạp	Dữ liệu nhỏ, đơn giản, các bài toán phân loại và hồi quy cơ bản
RANDOM FOREST	- Hiệu suất cao, giảm overfitting - Khả năng xử lý dữ liệu có nhiều đặc trưng - Ít nhạy cảm với outliers	- Mô hình phức tạp, khó giải thích chi tiết - Tốn nhiều tài nguyên tính toán hơn Decision Tree	Dữ liệu lớn, nhiều đặc trưng, các bài toán phân loại và hồi quy phức tạp
ADABOOST	- Hiệu suất cao, đặc biệt với dữ liệu không cân bằng - Khả năng kết hợp nhiều mô hình yếu để tăng độ chính xác	- Nhạy cảm với dữ liệu nhiễu - Khó chọn lựa hyperparameter - Có thể bị overfitting nếu không điều chỉnh cẩn thận	Dữ liệu không cân bằng, các bài toán phân loại nhị phân, tăng cường hiệu suất của các mô hình khác

2.10 Data Collector

Dưới đây là bảng thống kê giải thích các giá trị đặc trưng của cột trong DataFrame:

Tên cột	Giải thích
Has title	Kiểm tra xem trang web có thẻ <title> hay không.
Has input	Kiểm tra xem trang web có thẻ <input> hay không.
Has button	Kiểm tra xem trang web có thẻ <button> hay không.
Has image	Kiểm tra xem trang web có thẻ hay không.
Has submit	Kiểm tra xem trang web có thẻ <input type="submit"> hay không.
Has link	Kiểm tra xem trang web có thẻ <a> hay không.
Has Password	Kiểm tra xem trang web có thẻ <input type="password"> hay không.
Has email input	Kiểm tra xem trang web có thẻ <input type="email"> hay không.
Has_hidden_element	Kiểm tra xem trang web có thẻ <input type="hidden"> hay không.
Has_audio	Kiểm tra xem trang web có thẻ <audio> hay không.
Has_video	Kiểm tra xem trang web có thẻ <video> hay không.
Number_of_inputs	Đếm số lượng thẻ <input> trên trang web.
Number_of_buttons	Đếm số lượng thẻ <button> trên trang web.

Number_of_images	Đếm số lượng thẻ trên trang web.
Number_of_option	Đếm số lượng thẻ<option> trên trang web.
Number_of_list	Đếm số lượng thẻ và trên trang web.
Number_of_th	Đếm số lượng thẻ <th> trên trang web.
Number_of_tr	Đếm số lượng thẻ <tr> trên trang web.
Number_of_href	Đếm số lượng thuộc tính href trong các thẻ <a>.
Number_of_paragraph	Đếm số lượng thẻ <p> trên trang web.
Number_of_script	Đếm số lượng thẻ <script> trên trang web.
Length_of_title	Đo độ dài của nội dung trong thẻ <title>.
Has_h1	Kiểm tra xem trang web có thẻ <h1> hay không.
Has_h2	Kiểm tra xem trang web có thẻ <h2> hay không.
Has_h3	Kiểm tra xem trang web có thẻ <h3> hay không.
Length_of_text	Đo độ dài của toàn bộ văn bản trên trang web.
Number_of_clickable_button	Đếm số lượng nút bấm có thể nhấp trên trang web.
Number_of_a	Đếm số lượng thẻ <a> trên trang web.
Number_of_img	Đếm số lượng thẻ trên trang web.
Number_of_div	Đếm số lượng thẻ <div> trên trang web.
Number_of_figure	Đếm số lượng thẻ <figure> trên trang web.
Has_footer	Kiểm tra xem trang web có thẻ

	<footer> hay không.
Has_form	Kiểm tra xem trang web có thẻ <form> hay không.
Has_text_area	Kiểm tra xem trang web có thẻ <textarea> hay không.
Has_iframe	Kiểm tra xem trang web có thẻ <iframe> hay không.
Has_text_input	Kiểm tra xem trang web có thẻ <input type="text"> hay không.
Number_of_meta	Đếm số lượng thẻ <meta> trên trang web.
Has_nav	Kiểm tra xem trang web có thẻ <nav> hay không.
Has_object	Kiểm tra xem trang web có thẻ <object> hay không.
Has_picture	Kiểm tra xem trang web có thẻ <picture> hay không.
Number_of_sources	Đếm số lượng thẻ <source> trên trang web.
Number_of_span	Đếm số lượng thẻ trên trang web.
Number_of_table	Đếm số lượng thẻ <table> trên trang web.
URL	URL của trang web. Đây là thông tin nhận dạng duy nhất của mỗi trang web.
Label	Nhãn của trang web. Trong trường hợp này, tất cả các URL đã thu thập được gắn nhãn "legitimate" (hợp pháp) với giá trị là 0.

- Bảng này giúp hiểu rõ hơn về các đặc trưng được trích xuất từ các trang web và mục đích của từng đặc trưng trong việc phân loại các trang web là hợp pháp hay phishing. Các đặc trưng này sẽ được sử dụng để xây dựng các vector đặc trưng, sau đó được sử dụng để huấn luyện các mô hình học máy nhằm phân loại các trang web.
- Mục đích của việc lấy các giá trị của các cột trong DataFrame là để trích xuất các đặc trưng (features) từ các trang web. Các đặc trưng này sẽ được sử dụng để huấn luyện các mô hình học máy nhằm phân loại các trang web là hợp pháp (legitimate) hay phishing. Dưới đây là giải thích chi tiết về mục đích của từng đặc trưng:

Tên Cột	Mục Đích
has_title	Xác định xem trang web có tiêu đề hay không. Các trang web hợp pháp thường có tiêu đề rõ ràng.
has_input	Xác định xem trang web có các trường nhập liệu hay không. Các trang web phishing thường có nhiều trường nhập liệu để thu thập thông tin người dùng.
has_button	Xác định xem trang web có các nút bấm hay không. Các trang web tương tác thường có nhiều nút bấm.
has_image	Xác định xem trang web có hình ảnh hay không. Hình ảnh có thể là dấu hiệu của một trang web hợp pháp.
has_submit	Xác định xem trang web có nút gửi biểu mẫu hay không. Các trang web phishing thường có nút gửi để thu thập thông tin.
has_link	Xác định xem trang web có các liên kết hay không. Các trang web hợp pháp

	thường có nhiều liên kết đến các trang khác.
has_password	Xác định xem trang web có trường nhập mật khẩu hay không. Các trang web phishing thường có trường nhập mật khẩu để đánh cắp thông tin.
has_email_input	Xác định xem trang web có trường nhập email hay không. Các trang web phishing thường yêu cầu nhập email.
has_hidden_element	Xác định xem trang web có các trường ẩn hay không. Các trường ẩn có thể được sử dụng để thu thập thông tin mà người dùng không biết.
has_audio	Xác định xem trang web có nhúng âm thanh hay không. Các trang web hợp pháp có thể sử dụng âm thanh để tăng tính tương tác.
has_video	Xác định xem trang web có nhúng video hay không. Video có thể là dấu hiệu của một trang web hợp pháp.
number_of_inputs	Đếm số lượng trường nhập liệu trên trang web. Số lượng trường nhập liệu có thể cho biết mức độ tương tác của trang web.
number_of_buttons	Đếm số lượng nút bấm trên trang web. Số lượng nút bấm có thể cho biết mức độ tương tác của trang web.
number_of_images	Đếm số lượng hình ảnh trên trang web. Số lượng hình ảnh có thể cho biết mức độ trực quan của trang web.

number_of_option	Đếm số lượng tùy chọn trong các danh sách chọn. Số lượng tùy chọn có thể cho biết mức độ phức tạp của biểu mẫu.
number_of_list	Đếm số lượng danh sách trên trang web. Danh sách có thể cho biết mức độ tổ chức của nội dung.
number_of_th	Đếm số lượng ô tiêu đề trong bảng. Số lượng ô tiêu đề có thể cho biết mức độ chi tiết của bảng.
number_of_tr	Đếm số lượng hàng trong bảng. Số lượng hàng có thể cho biết mức độ chi tiết của bảng.
number_of_href	Đếm số lượng liên kết trên trang web. Số lượng liên kết có thể cho biết mức độ liên kết của trang web.
number_of_paragraph	Đếm số lượng đoạn văn trên trang web. Số lượng đoạn văn có thể cho biết mức độ nội dung của trang web.
number_of_script	Đếm số lượng mã JavaScript trên trang web. Số lượng mã JavaScript có thể cho biết mức độ tương tác của trang web.
length_of_title	Đo độ dài của tiêu đề trang web. Độ dài tiêu đề có thể cho biết mức độ chi tiết của tiêu đề.
has_h1	Xác định xem trang web có tiêu đề chính hay không. Tiêu đề chính thường chứa thông tin quan trọng nhất của trang web.
has_h2	Xác định xem trang web có tiêu đề phụ hay không. Tiêu đề phụ thường chứa thông tin bổ sung.

has_h3	Xác định xem trang web có tiêu đề phụ hay không. Tiêu đề phụ thường chứa thông tin bổ sung.
length_of_text	Đo độ dài của toàn bộ văn bản trên trang web. Độ dài văn bản có thể cho biết mức độ nội dung của trang web.
number_of_clickable_button	Đếm số lượng nút bấm có thể nhấp trên trang web. Số lượng nút bấm có thể cho biết mức độ tương tác của trang web.
number_of_a	Đếm số lượng liên kết trên trang web. Số lượng liên kết có thể cho biết mức độ liên kết của trang web.
number_of_img	Đếm số lượng hình ảnh trên trang web. Số lượng hình ảnh có thể cho biết mức độ trực quan của trang web.
number_of_div	Đếm số lượng khối nội dung trên trang web. Số lượng khối nội dung có thể cho biết mức độ tổ chức của trang web.
number_of_figure	Đếm số lượng nhóm nội dung đa phương tiện trên trang web. Số lượng nhóm nội dung có thể cho biết mức độ trực quan của trang web.
has_footer	Xác định xem trang web có chân trang hay không. Chân trang thường chứa thông tin liên hệ và bản quyền.
has_form	Xác định xem trang web có biểu mẫu hay không. Biểu mẫu thường được sử dụng để thu thập thông tin từ người dùng.
has_text_area	Xác định xem trang web có trường nhập

	văn bản dài hay không. Trường nhập văn bản dài thường được sử dụng để thu thập ý kiến hoặc phản hồi.
has_iframe	Xác định xem trang web có nhúng nội dung từ trang web khác hay không. Nội dung nhúng có thể là dấu hiệu của một trang web hợp pháp hoặc phishing.
has_text_input	Xác định xem trang web có trường nhập văn bản hay không. Trường nhập văn bản thường được sử dụng để thu thập thông tin từ người dùng.
number_of_meta	Đếm số lượng thẻ metadata trên trang web. Metadata chứa thông tin về trang web và có thể ảnh hưởng đến SEO.
has_nav	Xác định xem trang web có thanh điều hướng hay không. Thanh điều hướng giúp người dùng di chuyển giữa các trang.
has_object	Xác định xem trang web có nhúng đối tượng đa phương tiện hay không. Đối tượng đa phương tiện có thể là dấu hiệu của một trang web hợp pháp.
has_picture	Xác định xem trang web có nhúng hình ảnh với các định dạng khác nhau hay không. Hình ảnh có thể là dấu hiệu của một trang web hợp pháp.
number_of_sources	Đếm số lượng nguồn đa phương tiện trên trang web. Số lượng nguồn có thể cho biết mức độ đa phương tiện của trang web.

number_of_span	Đếm số lượng phần tử nội dung nhỏ trên trang web. Số lượng phần tử nhỏ có thể cho biết mức độ chi tiết của trang web.
number_of_table	Đếm số lượng bảng trên trang web. Số lượng bảng có thể cho biết mức độ tổ chức của dữ liệu trên trang web.
URL	URL của trang web. Đây là thông tin nhận dạng duy nhất của mỗi trang web.
Label	Nhãn của trang web. Trong trường hợp này, tất cả các URL đã thu thập được gắn nhãn "legitimate" (hợp pháp) với giá trị là 0.

- Các đặc trưng này được sử dụng để xây dựng các vector đặc trưng, sau đó được sử dụng để huấn luyện các mô hình học máy nhằm phân loại các trang web. Việc trích xuất và sử dụng các đặc trưng này giúp mô hình học máy có thể học được các mẫu và đặc điểm của các trang web phishing và hợp pháp, từ đó đưa ra các dự đoán chính xác.

2.11

2.12 Phương pháp (Methodology)

Bước 1: Mục tiêu của nghiên cứu: Nghiên cứu nhằm phát triển một hệ thống phát hiện phishing dựa trên phân tích URL, sử dụng các thuật toán máy học khác nhau để cải thiện độ chính xác và hiệu suất phát hiện.

Bước 2: Phân tích URL:

- Nghiên cứu tập trung vào việc phân tích cấu trúc của URL, bao gồm các thành phần như:
 - + **Protocol:** Giao thức sử dụng (HTTP, HTTPS).
 - + **Hostname:** Tên miền của trang web.
 - + **Path:** Đường dẫn đến tài nguyên cụ thể trên máy chủ.
 - + **Query:** Các tham số truy vấn có thể có trong URL.
- Cấu trúc URL được phân tích để xác định các đặc trưng có thể giúp phân biệt giữa các trang web hợp pháp và lừa đảo.

Bước 3: Trích xuất đặc trưng:

- Nghiên cứu đã xác định và trích xuất tổng cộng 58 đặc trưng từ URL, bao gồm các yếu tố như độ dài của URL, sự xuất hiện của từ khóa nhất định, và các ký tự đặc biệt.
- Các đặc trưng này được phân loại thành các nhóm khác nhau để phục vụ cho việc phân tích.

Bước 4: Thuật toán máy học:

- Nghiên cứu áp dụng nhiều thuật toán máy học khác nhau để phân tích và phân loại các URL, bao gồm nhưng không giới hạn ở:
 - + Decision Trees
 - + Random Forest
 - + Ada Boost
- Mỗi thuật toán được huấn luyện trên các bộ dữ liệu đã được chuẩn bị và sau đó được đánh giá về độ chính xác và thời gian huấn luyện.

Bước 5: So sánh và đánh giá:

- Kết quả từ các mô hình được so sánh với nhau để xác định mô hình nào hoạt động tốt nhất trong việc phát hiện phishing.

- Các chỉ số đánh giá như độ chính xác, độ nhạy, và độ đặc hiệu được sử dụng để đo lường hiệu suất của từng mô hình.

Bước 6: Kế hoạch tương lai:

- Nghiên cứu cũng đề xuất việc tạo ra một bộ dữ liệu lớn hơn cho các hệ thống phát hiện phishing dựa trên URL trong tương lai, cũng như việc áp dụng các thuật toán lai và mô hình học sâu để cải thiện hơn nữa hiệu suất phát hiện.

CHƯƠNG 3: KẾT QUẢ THỰC NGHIỆM

3.1 Quá trình tạo file CSV

1. Chuẩn bị tệp CSV đầu vào

- **Nguồn dữ liệu:** Tải về tệp CSV chứa danh sách URL từ hai nguồn:
 - + **Phishing URLs:** Từ trang web phishtank.org(PhishTank)
 - + **Legitimate URLs:** Từ trang web tranco-list.eu (Alexa Top Sites).
- Sau khi tải về, cả hai tệp CSV này cần được lưu vào cùng một thư mục có tên là Dataset với mã Python.

2. Chuyển đổi CSV thành DataFrame

- **Sử dụng Pandas:** Mã sử dụng thư viện pandas để chuyển đổi các tệp CSV thành DataFrame.

```
URL_file_name = "Dataset/PhishTank.csv"
data_frame = pd.read_csv(URL_file_name)
```

Hình 3.3 Đọc dữ liệu từ PhishTank

```
URL_file_name = "Dataset/Alexa.csv"
data_frame = pd.read_csv(URL_file_name)
```

Hình 3.4 Đọc dữ liệu từ Alexa Top Sites

- **Lọc dữ liệu:** Một số cột không cần thiết có thể tồn tại trong DataFrame, do đó chỉ giữ lại cột chứa URL.

```
# chỉ lấy cột "url" và chuyển đổi nó thành một danh sách
URL_list = data_frame['url'].to_list()
```

Hình 3.5 Lấy cột URL và chuyển thành danh sách

3. Tạo danh sách URL

- Tạo một danh sách chứa các URL từ DataFrame đã được lọc.
 - + Tạo 1 file có tên là Unsafe.csv để lưu các danh sách Url lừa đảo (Phishing) đã được lọc

```
# Lưu DataFrame vào file CSV (mã hóa UTF-8)
df.to_csv("Dataset/Unsafe.csv", mode='a', index=False, header=False, encoding='utf-8')

print("Thu thập dữ liệu hoàn tất! Kết quả được lưu vào Dataset/Unsafe.csv")
```

Hình 3.6 Lưu DataFrame Unsafe vào file

- + Tạo 1 file có tên là Safe.csv để lưu các danh sách Url hợp lệ (Legitimate) đã được lọc

```
# Lưu DataFrame vào file CSV (mã hóa UTF-8)
df.to_csv("Dataset/Safe.csv", mode='a', index=False, header=False, encoding='utf-8')

print("Thu thập dữ liệu hoàn tất! Kết quả được lưu vào Dataset/Safe.csv")
```

Hình 3.7 Lưu DataFrame Safe vào file

4. Thu thập Dữ liệu:

- Đối với mỗi URL trong danh sách, mã lệnh gửi yêu cầu HTTP để lấy dữ liệu HTML từ trang web.
- Sau đó, mã lệnh sử dụng BeautifulSoup để phân tích cú pháp HTML và trích xuất các đặc trưng cần thiết.
- Một vector được tạo ra cho mỗi trang web, chứa các giá trị số tương ứng với các đặc trưng đã được trích xuất.

5. Tạo DataFrame cấu trúc:

- Tất cả các vector được thu thập sẽ được thêm vào một danh sách, và cuối cùng, danh sách này sẽ được chuyển đổi thành một DataFrame mới.
- DataFrame này sẽ chứa các cột từ các đặc trưng đã trích xuất cùng với cột URL.

6. Chuyển đổi DataFrame thành CSV:

- Mã lệnh sẽ kiểm tra nếu tệp CSV đã tồn tại hay chưa. Nếu có, thì dữ liệu mới sẽ được thêm vào tệp (append) thay vì tạo một tệp mới mỗi lần.
- Điều này được thực hiện bằng cách sử dụng chế độ "append" khi ghi dữ liệu vào tệp CSV.

7. Gán nhãn Dữ liệu:

- Cuối cùng, mã lệnh sẽ thêm một cột nhãn vào DataFrame.
- Nếu URL là từ danh sách lừa đảo, nhãn sẽ là 1; nếu là từ danh sách hợp pháp, nhãn sẽ là 0.
- Sau đó, DataFrame đã được cấu trúc và gán nhãn sẽ được lưu vào tệp CSV.


3.2 Quá trình train dữ liệu

1. Quá trình Train và Chia tập dữ liệu

- **Chia tập dữ liệu:** Dữ liệu được chia thành tập huấn luyện và tập kiểm tra. Tỷ lệ chia thường là 80% cho tập huấn luyện và 20% cho tập kiểm tra. Điều này có nghĩa là 20% dữ liệu sẽ được dùng để kiểm tra mô hình sau khi nó đã được huấn luyện.
- **Cách thực hiện:** Sử dụng hàm `train_test_split` từ thư viện `scikit-learn`, với tham số `test_size` được đặt là 0.2, tức là 20% dữ liệu sẽ là tập kiểm tra.
- **Kết quả mô hình**
 - o Sau khi huấn luyện mô hình, các chỉ số hiệu suất được tính toán bao gồm:
- **Độ chính xác (Accuracy):** Tỷ lệ đúng giữa các dự đoán và nhãn thật.
- **Độ tinh khiết (Precision):** Tỷ lệ giữa các dự đoán đúng là dương và tổng số dự đoán dương.
- **Độ nhạy (Recall):** Tỷ lệ giữa các dự đoán đúng là dương và tổng số thực tế dương.

3. Bảng thống kê kết quả

Dưới đây là một bảng thống kê cho các chỉ số hiệu suất:



Hình 3.8 Biểu đồ cột so sánh của 3 mô hình				Nhận xét tổng quan
	accuracy	precision	recall	
Decision Tree	0.9852 (98.52%)	0.6896(68.96%)	0,6916(69.16%)	Độ chính xác cao, nhưng precision và recall trung bình.
Random Forest	0,9908(99.08%)	0,8665(86.65%)	0,6617(66.17%)	Hiệu suất tổng thể tốt nhất, precision cao nhưng cần cải thiện recall.
AdaBoost	0.9775(97.75%)	0.4866(48.66%)	0,1648(16.48%)	Hiệu suất kém, không phù hợp cho bài toán có dữ liệu dương quan trọng.


Bảng 3.2 So sánh và nhận xét tổng quan 3 mô hình

Kết luận:


- **Random Forest** là lựa chọn tốt nhất nếu ưu tiên độ chính xác tổng thể và precision.
- **Decision Tree** phù hợp hơn nếu cần cân bằng giữa precision và recall.
- **AdaBoost** không được khuyến nghị trong trường hợp này do hiệu suất kém ở cả precision và recall.

*Chú thích :


- Accuracy (Độ chính xác)
- Precision (Độ chính xác theo kết quả dương)
- Recall (Độ nhạy)



Hình 3.9 Giao diện Website



Hình 3.10 Chọn Model cho Machine Learning



Hình 3.11 Giao diện nhập 1 url bất kì kết quả trả về : An toàn

Please select your machine learning model

Decision Tree

DT model is selected!

Enter the URL

<http://web.tiscali.it/habbo/>

Check!

Attention! This web page is a potential PHISHING!

Hình 3.12 Giao diện nhập 1 url bất kì kết quả trả về : Không an toàn

	accuracy	precision	recall
Decision Tree	0.9846	0.6737	0.7039
Random Forest	0.9904	0.8325	0.6485
AdaBoost	0.9777	0.4814	0.1450

Hình 3.13 Train thuật toán và kết quả đạt được

CHƯƠNG 4: KẾT LUẬN VÀ KIẾN NGHỊ

4.1 Kết luận

- Hệ thống phát hiện website lừa đảo bằng học máy đã chứng minh được hiệu quả trong việc nhận diện và ngăn chặn các cuộc tấn công phishing. Thông qua việc huấn luyện mô hình trên một lượng lớn dữ liệu, hệ thống có khả năng:
- **Phân loại chính xác:** Nhận biết các đặc trưng đặc trưng của website lừa đảo như URL giả mạo, nội dung đáng ngờ, hình ảnh lừa đảo, và các kỹ thuật xã hội hóa khác.
- **Phát hiện nhanh chóng:** Phát hiện các website lừa đảo mới xuất hiện một cách nhanh chóng, giúp giảm thiểu thiệt hại cho người dùng.
- **Tự động hóa quá trình:** Tự động hóa quá trình phân tích và đánh giá, giảm thiểu sự can thiệp của con người và tăng hiệu quả làm việc.

Tuy nhiên, việc xây dựng và triển khai một hệ thống như vậy cũng còn một số hạn chế như:

- **Dữ liệu:** Cần một lượng lớn dữ liệu chất lượng cao để huấn luyện mô hình, đặc biệt là dữ liệu về các loại tấn công phishing mới.
- **Tiến hóa của mối đe dọa:** Các thủ đoạn của kẻ tấn công không ngừng thay đổi, đòi hỏi hệ thống phải được cập nhật liên tục.
- **Sai sót:** Hệ thống vẫn có thể mắc phải một số sai sót trong việc phân loại, đặc biệt là đối với các trường hợp phức tạp.

4.2 Kiến nghị

- Để nâng cao hiệu quả của hệ thống phát hiện website lừa đảo bằng học máy, chúng tôi đưa ra một số kiến nghị sau:

1. Mở rộng và Cải tiến Tập Dữ liệu

- **Đa dạng hóa các loại tấn công:**

Thu thập dữ liệu về các loại tấn công phishing mới nổi như: phishing nhắm mục tiêu (targeted phishing), phishing qua mạng xã hội, phishing qua email, SMS phishing.

Tập trung vào các biến thể mới của các cuộc tấn công cũ, bao gồm cả các cuộc tấn công sử dụng kỹ thuật ngụy trang tinh vi.

- **Tăng cường dữ liệu có tính cá nhân hóa cao:**

Thu thập dữ liệu từ các cuộc tấn công nhắm vào các đối tượng cụ thể (ví dụ: nhân viên của một tổ chức, khách hàng của một ngân hàng).

Sử dụng các kỹ thuật tạo dữ liệu tổng hợp để tăng cường số lượng dữ liệu có tính cá nhân hóa.

- **Cập nhật liên tục:**

Xây dựng một quy trình tự động để thu thập và cập nhật dữ liệu mới một cách thường xuyên.

Sử dụng các công cụ và dịch vụ theo dõi các hoạt động tấn công phishing trên mạng.

2. Nâng Cao Độ Phức Tạp của Mô Hình

- **Sử dụng các kiến trúc học sâu tiên tiến:**

- + **Mạng thần kinh tuần hoàn (RNN):** Đề xuất sử dụng RNN để nắm bắt các mối quan hệ tuần tự trong dữ liệu, đặc biệt hữu ích cho việc phân tích các cuộc tấn công phishing có nhiều giai đoạn.

- + **Mạng đối kháng sinh thành (GAN):** Tạo ra các mẫu dữ liệu tổng hợp để tăng cường tập dữ liệu huấn luyện và cải thiện khả năng phát hiện các cuộc tấn công mới.

- + **Transformer:** Áp dụng Transformer để xử lý dữ liệu văn bản và mã nguồn, giúp phát hiện các mẫu ngôn ngữ đặc trưng của các trang web lừa đảo.
- **Trích xuất các đặc trưng sâu:**
 - + Sử dụng các kỹ thuật trích xuất đặc trưng tự động như Word Embedding, BERT để tìm ra các đặc trưng ẩn sâu trong dữ liệu văn bản.
 - + Kết hợp các đặc trưng hình ảnh và video để phân tích các trang web lừa đảo có chứa các yếu tố trực quan.

3. Tích Hợp với Các Hệ Thống Khác

- **Tích hợp với hệ thống DNS:**
 - + Sử dụng DNS Sinkhole để chặn truy cập đến các trang web lừa đảo đã được xác định.
- **Tích hợp với các hệ thống SIEM:**
 - + Thu thập và phân tích các log từ các hệ thống khác nhau để phát hiện các dấu hiệu bất thường liên quan đến các cuộc tấn công phishing.
- **Tích hợp với các hệ thống bảo mật email:**
 - + Phân tích các email đi và đến để phát hiện các liên kết độc hại và các tệp đính kèm nguy hiểm.

4. Đánh Giá và Cải Tiến Liên Tục

- **Đánh giá hiệu suất:**
 - + Sử dụng các chỉ số đánh giá như độ chính xác, độ nhạy, độ đặc hiệu để đánh giá hiệu suất của mô hình.
 - + Thực hiện đánh giá trên các tập dữ liệu độc lập để đảm bảo tính khách quan.
- **Cải tiến liên tục:**
 - + Điều chỉnh siêu tham số của mô hình để tối ưu hóa hiệu suất.
 - + Thường xuyên cập nhật mô hình bằng dữ liệu mới.
- **Phản hồi của người dùng:**

- + Thu thập phản hồi từ người dùng để xác định các trường hợp sai sót và cải thiện mô hình.

5. Nhận Thức Cộng Đồng

- Tuyên truyền:

- + Tổ chức các buổi đào tạo, hội thảo để nâng cao nhận thức của người dùng về các mối đe dọa từ phishing.
- + Phát triển các tài liệu hướng dẫn dễ hiểu về cách nhận biết và tránh các cuộc tấn công phishing.

- Cộng đồng chia sẻ:

- + Xây dựng một cộng đồng chia sẻ thông tin về các cuộc tấn công phishing mới và các biện pháp phòng ngừa.

TÀI LIỆU THAM KHẢO

<https://www.mdpi.com/2072-4292/16/4/665>

<https://www.sciencedirect.com/science/article/pii/S0169136823003682>

<https://www.sciencedirect.com/science/article/abs/pii/S0022169423005413>

<https://www.sciencedirect.com/science/article/abs/pii/S1574954123002236>

<https://ieeexplore.ieee.org/abstract/document/10060798>

<https://www.mdpi.com/2075-4418/13/19/3069>

<https://link.springer.com/article/10.1140/epjs/s11734-024-01308-x>

CÔNG CỤ THỰC HIỆN

Dưới đây là danh sách liệt kê các công cụ thực hiện trong project này.

STT	Công cụ	Link download
1	Python	https://www.python.org/
2	Dataset : PhishTank	https://phishtank.org/developer_info.php
3	Dataset : Alexa Top Sites	https://www.expireddomains.net/alexa-top-websites/

PHƯƠNG PHÁP THỰC HIỆN

STT	Phương pháp	Nguyên lý hoạt động
1	Thuật toán AdaBoost	AdaBoost hoạt động bằng cách tuần tự xây dựng các cây quyết định. Sau mỗi lần xây dựng, trọng số của các mẫu dữ liệu bị phân loại sai sẽ được tăng lên. Cây quyết định tiếp theo sẽ tập trung vào việc phân loại chính xác các mẫu có trọng số cao này. Quá trình này được lặp lại nhiều lần cho đến khi đạt được độ chính xác mong

		muốn.
2	Decision Tree	Decision Tree là một mô hình phân loại hoặc hồi quy có cấu trúc giống như một cây. Mỗi nút trong cây đại diện cho một thuộc tính, mỗi cạnh đại diện cho một giá trị của thuộc tính đó, và mỗi lá đại diện cho một lớp (trong phân loại) hoặc một giá trị dự đoán (trong hồi quy).
3	Random Forest	Random Forest là một tập hợp các cây quyết định. Mỗi cây được xây dựng trên một tập hợp mẫu ngẫu nhiên của dữ liệu và chỉ sử dụng một tập hợp thuộc tính ngẫu nhiên. Dự đoán cuối cùng được đưa ra bằng cách bình chọn đa số (trong phân loại) hoặc trung bình (trong hồi quy) của các cây.